**Московский государственный технический университет им. Н.Э.Баумана**
**Кафедра «Системы обработки информации и управления»**

Лабораторная работа №2 по
дисциплине
«Методы машинного обучения» на
тему
# «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Выполнил:
Студент группы ИУ5-21М Ся Бэйбэй

_____

Москва — 2022г.

# 1. Цель лабораторной работы

Изучить способы предварительной обработки данных для дальнейшего формирования моделей [1].

# 2. Задание

Требуется [1]:

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных.
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:

   - обработку пропусков в данных;
   - кодирование категориальных признаков;
   - масштабирование данных.

# 3. Ход выполнения работы

Подключим все необходимые библиотеки и настроим отображение графиков :

In [50]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import sklearn.impute
import sklearn.preprocessing
%matplotlib inline
sns.set(style="ticks")
```

Зададим ширину текстового представления данных, чтобы в дальнейшем текст в отчёте влезал на А4 :

```
In [2]: pd.set_option("display.width", 70)
```

Для выполнения данной лабораторной работы возьмём набор данных по приложениям в Covid_19 Data:

```
In [3]: data = pd.read_csv("covid_19_clean_complete_2022.csv")
```

Посмотрим на эти наборы данных:

```
In [5]: data.dtypes
```

```
In [9]: data.dtypes

Out[9]: Province/State     object
        Country/Region     object
        Lat               float64
        Long              float64
        Date               object
        Confirmed           int64
        Deaths              int64
        Recovered           int64
        Active              int64
        WHO Region         object
        dtype: object
```

```
In [10]: data.shape

Out[10]: (214894, 10)
```

```
In [11]: data.isnull().sum()

Out[11]: Province/State    149189
         Country/Region         0
         Lat                 1546
         Long                1546
         Date                   0
         Confirmed              0
         Deaths                 0
         Recovered              0
         Active                 0
         WHO Region          2319
         dtype: int64
```

## 3.1. Обработка пропусков в данных

Найдем все пропуски в данных:

```
In [11]: data.isnull().sum()

Out[11]: Province/State    149189
         Country/Region         0
         Lat                 1546
         Long                1546
         Date                   0
         Confirmed              0
         Deaths                 0
         Recovered              0
         Active                 0
         WHO Region          2319
         dtype: int64
```

```
In [15]: hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
         [(c, data[c].isnull().sum()) for c in hcols_with_na]
         [(c, data[c].isnull().mean()) for c in hcols_with_na]

Out[15]: [('Province/State', 0.6942446043165468),
          ('Lat', 0.007194244604316547),
          ('Long', 0.007194244604316547),
          ('WHO Region', 0.01079136690647482)]
```

Очевидно, что мы выпустим с колонкой `Province/State`.

```
In [19]: data_de=data.drop(["Province/State"],axis=1)

In [20]: data_de.dtypes

Out[20]: Country/Region     object
         Lat               float64
         Long              float64
         Date               object
         Confirmed           int64
         Deaths              int64
         Recovered           int64
         Active              int64
         WHO Region         object
         dtype: object
```

Очевидно, что мы будем работать с колонкой `Lat`.

```
In [58]: from sklearn.impute import SimpleImputer
         from sklearn.impute import MissingIndicator

In [59]: def impute_column(dataset, column, strategy_param, fill_value_param=None):
             """
             Заполнение пропусков в одном признаке
             """
             temp_data = dataset[[column]].values
             size = temp_data.shape[0]

             indicator = MissingIndicator()
             mask_missing_values_only = indicator.fit_transform(temp_data)

             imputer = SimpleImputer(strategy=strategy_param,
                                     fill_value=fill_value_param)
             all_data = imputer.fit_transform(temp_data)

             missed_data = temp_data[mask_missing_values_only]
             filled_data = all_data[mask_missing_values_only]

             return all_data.reshape((size,)), filled_data, missed_data

In [63]: def research_impute_numeric_column(dataset, num_column, const_value=None):
             strategy_params = ['mean', 'median', 'most_frequent', 'constant']
             strategy_params_names = ['Среднее', 'Медиана', 'Мода']
             strategy_params_names.append('Константа = ' + str(const_value))

             original_temp_data = dataset[[num_column]].values
             size = original_temp_data.shape[0]
             original_data = original_temp_data.reshape((size,))

             new_df = pd.DataFrame({'Исходные данные':original_data})

             for i in range(len(strategy_params)):
                 strategy = strategy_params[i]
                 col_name = strategy_params_names[i]
                 if (strategy!='constant') or (strategy == 'constant' and const_value!=None):
                     if strategy == 'constant':
                         temp_data, _, _ = impute_column(dataset, num_column, strategy, fill_value_param=const_value)
                     else:
                         temp_data, _, _ = impute_column(dataset, num_column, strategy)
                     new_df[col_name] = temp_data

             sns.kdeplot(data=new_df)

In [69]: research_impute_numeric_column(data_de, "Lat", 98.2)
```

```
In [69]: research_impute_numeric_column(data_de, "Lat", 98.2)
```

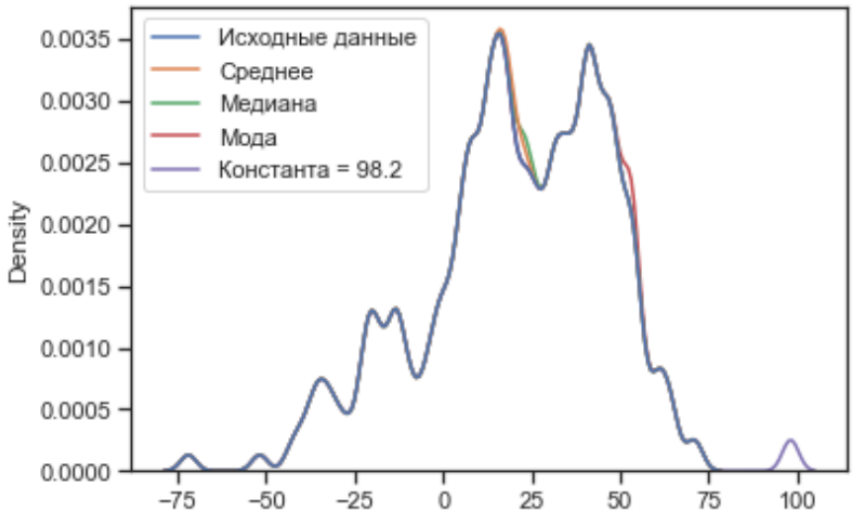


Очевидно, что использование этих методов приводит к незначительным различиям в кон
ечных результатах. Но я думаю, что метод “Среднее” относительно хороший.

## 3.2. Кодирование категориальных признаков

Рассмотрим колонку `Type`:

```
In [117]: types =data_de["WHO Region"].dropna().astype(str)
          types.value_counts()

Out[117]: Europe                  64159
          Western Pacific         50245
          Americas                37104
          Africa                  36331
          Eastern Mediterranean   17006
          South-East Asia          7730
          Name: WHO Region, dtype: int64
```

Выполним кодирование категорий целочисленными значениями:

In [128]:
```
from category_encoders.count import CountEncoder as ce_CountEncode
from category_encoders.target_encoder import TargetEncoder as ce_TargetEncoder
```

In [126]:
```
ce_CountEncoder2 = ce_CountEncoder(normalize=True)
data_FREQ_ENC = ce_CountEncoder2.fit_transform(data_de[data_de.columns.difference(['Survived'])])
data_FREQ_ENC
```

Out[126]:

| | Active | Confirmed | Country/Region | Date | Deaths | Lat | Long | Recovered | WHO Region |
|---|---|---|---|---|---|---|---|---|---|
| **0** | 0 | 0 | 0.003597 | 0.001294 | 0 | 33.939110 | 67.709953 | 0 | 0.079137 |
| **1** | 0 | 0 | 0.003597 | 0.001294 | 0 | 41.153300 | 20.168300 | 0 | 0.298561 |
| **2** | 0 | 0 | 0.003597 | 0.001294 | 0 | 28.033900 | 1.659600 | 0 | 0.169065 |
| **3** | 0 | 0 | 0.003597 | 0.001294 | 0 | 42.506300 | 1.521800 | 0 | 0.298561 |
| **4** | 0 | 0 | 0.003597 | 0.001294 | 0 | -11.202700 | 17.873900 | 0 | 0.169065 |
| **...** | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| **214889** | 644414 | 649971 | 0.003597 | 0.001294 | 5557 | 31.952200 | 35.233200 | 0 | 0.079137 |
| **214890** | 530 | 530 | 0.003597 | 0.001294 | 0 | 39.904200 | 116.407400 | 0 | 0.010791 |
| **214891** | 9639 | 11774 | 0.003597 | 0.001294 | 2135 | 15.552727 | 48.516388 | 0 | 0.079137 |
| **214892** | 309655 | 313613 | 0.003597 | 0.001294 | 3958 | -13.133897 | 27.849332 | 0 | 0.169065 |
| **214893** | 233342 | 238739 | 0.003597 | 0.001294 | 5397 | -19.015438 | 29.154857 | 0 | 0.169065 |

214894 rows × 9 columns

In [125]:
```
data_FREQ_ENC['WHO Region'].unique()
```

Out[125]:
```
array([0.07913669, 0.29856115, 0.16906475, 0.01079137, 0.17266187,
       0.23381295, 0.03597122])
```

## 3.3. Масштабирование данных

Для начала попробуем обычное MinMax-масштабирование и StandardScaler:

In [153]:
```
mm = sklearn.preprocessing.MinMaxScaler()
sns.kdeplot(data=mm.fit_transform(data_de[["Lat"]]), shade=True, color="g")
```

Out[153]: <AxesSubplot:ylabel='Density'>

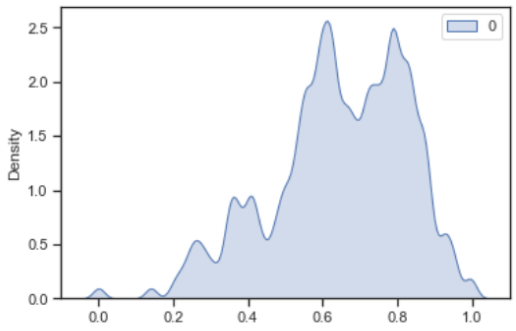


In [154]:
```
mm = sklearn.preprocessing.StandardScaler()
sns.kdeplot(data=mm.fit_transform(data_de[["Lat"]]), shade=True, color="g")
```

Out[154]: <AxesSubplot:ylabel='Density'>

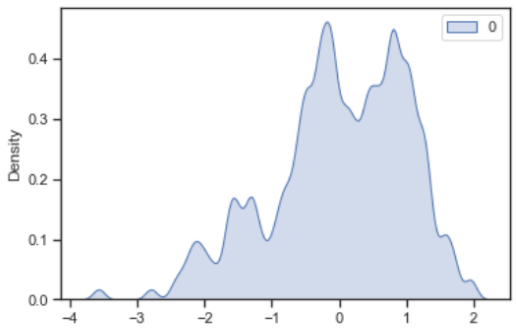


In [155]:
```
mm = sklearn.preprocessing.RobustScaler()
sns.kdeplot(data=mm.fit_transform(data_de[["Lat"]]), shade=True, color="g")
```

Результат вполне ожидаемый и вполне приемлемый. Но попробуем и другие варианты, например, масштабирование на основе RobustScaler:

```
In [155]: mm = sklearn.preprocessing.RobustScaler()
          sns.kdeplot(data=mm.fit_transform(data_de[["Lat"]]), shade=True, color="g")

Out[155]: <AxesSubplot:ylabel='Density'>
```

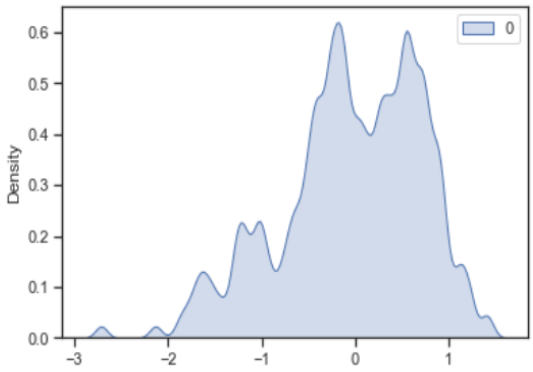


Также результат ожидаемый, но его применимость зависит от дальнейшего использования.

# Список литературы

[1] COVID -19 Global Reports early March 2022 [Electronic resource] // Kaggle. — 2022. — Access mode: https://www.kaggle.com/danielfesalbon/covid-19-global-reports-early-march-2022 (online; accessed:16.03.2022).