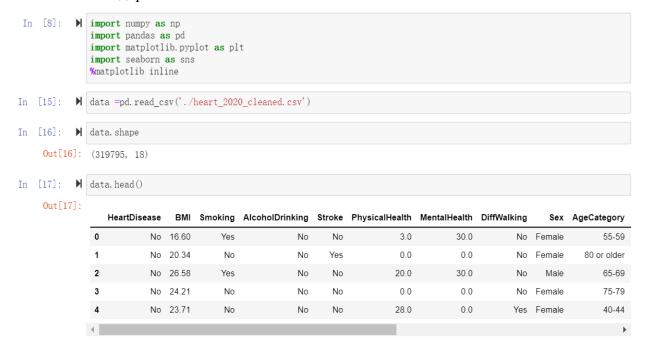
Московский государственный технический университет им. Н.Э.Баумана Кафедра «Системы обработки информации и управления»

Рубежный контроль №1 по дисциплине «Методы машинного обучения»

Выполнил: Студент группы ИУ5И-21М Ся Бэйбэй

Загрузка и просмотр датасета

Датасет содержит данные ежегодного опроса CDC за 2020 год о 400 000 взрослых, связанные с состоянием их здоровья.



```
In [18]: | data.isna().sum()
         Out[18]: HeartDisease
                             BMI
                             Smoking
                             AlcoholDrinking
                             Stroke
                             PhysicalHealth
                             MentalHealth
                             DiffWalking
                             Sex
                            AgeCategory
                             Race
                             Diabetic
                             PhysicalActivity 0
                            GenHealth U
                             SleepTime
                             Asthma
                             KidneyDisease
                             SkinCancer
                             dtype: int64
In [19]: ► data.info()
                             <class 'pandas.core.frame.DataFrame'>
                             RangeIndex: 319795 entries, 0 to 319794
                             Data columns (total 18 columns):
                             # Column
                                                             Non-Null Count Dtype

        0
        HeartDisease
        319795 non-null object

        1
        BMI 319795 non-null float64

        2
        Smoking 319795 non-null object

        3
        AlcoholDrinking 319795 non-null object

        4
        Stroke 319795 non-null object

                               5 PhysicalHealth 319795 non-null float64
                              6 Mentalhealth 319795 non-null float64
7 DiffWalking 319795 non-null object
8 Sex 319795 non-null object
9 AgeCategory 319795 non-null object
10 Race 319795 non-null object
11 Diabetic 319795 non-null object
                              12 PhysicalActivity 319795 non-null object

        13
        GenHealth
        319795 non-null object

        14
        SleepTime
        319795 non-null float64

        15
        Asthma
        319795 non-null object

        16
        KidneyDisease
        319795 non-null object

        17
        SkinCancer
        319795 non-null object

                             dtypes: float64(4), object(14)
```

1. Задание 17

Для набора данных проведите нормализацию для одного (произвольного) числового признака с использованием преобразования Йео-Джонсона (Yeo-Johnson transformation).

```
In [20]: M def diagnostic_plots(df, variable):
                      plt.figure(figsize=(15,6))
                       # гистограмма
                      plt.subplot(1, 2, 1)
                       df[variable].hist(bins=30)
                       ## Q-Q plot
                       plt.subplot(1, 2, 2)
                       stats.probplot(df[variable], dist="norm", plot=plt)
                       plt.show()
In [23]: 
# Необходимо преобразовать данные к действительному типу data['BMI_yeojohnson'], param = stats.yeojohnson(data['BMI']) print('Оптимальное значение λ = {}'.format(param)) diagnostic_plots(data, 'BMI_yeojohnson')
                   Оптимальное значение \lambda = -0.6727186978751638
                                                                                                                    Probability Plot
                                                                                         1.425
                   40000
                                                                                         1.400
                   35000
                                                                                         1.375
                   30000
                                                                                      sale Napro 1325
1325
1300
                   25000
                   20000
                                                                                         1.275
                   10000
                                                                                         1.250
                    5000
                                       1275 1300 1325 1350
                                                                  1.375 1.400
                                                                                                                   0
Theoretical quantiles
```

Scatter:

In [65]: data2 =pd.read_csv('./Height of Male and Female by Country 2022.csv') data2. shape Out[65]: (199, 6) In [66]: ▶ sns. heatmap(data2.corr(), annot=True, fmt=".4f") Out[66]: <AxesSubplot:> -1.00 Rank - 1.0000 -0.9920 -0.9242 -0.9919 -0.9232 - 0.75 - 0.50 Male Height in Cm -0.9920 1.0000 0.9288 0.9999 0.9276 0.25 Female Height in Cm -0.9242 0.9288 1.0000 0.9284 0.9998 0.00 -0.25 Male Height in Ft -0.9919 0.9999 0.9284 1.0000 0.9273 -0.50 -0.75 Female Height in Ft -0.9232 0.9276 0.9998 0.9273 1.0000 Height in Ft Female Height in Ft Male Height in Cm Female Height in Cm Rank In [67]: M data2.corr() Out[67]: Rank Male Height in Cm Female Height in Cm Male Height in Ft Female Height in Ft Rank 1.000000 -0.992041 -0.924239 -0.991887 -0.923155 Male Height in Cm -0.992041 1.000000 0.928787 0.999854 0.927642 Female Height in Cm -0.924239 0.928787 1.000000 0.928406 0.999792 Male Height in Ft -0.991887 0.999854 0.928406 1.000000 0.927259 Female Height in Ft -0.923155 1.000000 0.927642 0.999792 0.927259 In [67]: data2.corr() Out[67]: Rank Male Height in Cm Female Height in Cm Male Height in Ft Female Height in Ft Rank 1.000000 -0.992041 -0.924239 -0.991887 -0.923155 Male Height in Cm -0.992041 1.000000 0.928787 0.999854 0.927642 Female Height in Cm -0.924239 0.928787 1.000000 0.928406 0.999792 Male Height in Ft -0.991887 0.999854 0.928406 1.000000 0.927259 Female Height in Ft -0.923155 1.000000 0.927642 0.999792 0.927259 x=data2['Male Height in Cm'] y=data2['Rank'] In [64]: plt.scatter(x, y) Out[64]: <matplotlib.collections.PathCollection at 0x208386e9f40> 200 175 150 125

180

170

165

175

160

2. Задание 37

Для набора данных проведите процедуру отбора признаков (feature selection). Используйте класс <u>SelectPercentile</u> для 5% лучших признаков, и метод, основанный на взаимной информации.